

# SRS. Иерархия Хомского. Регулярные грамматики

---

Теория формальных языков  
*2021 г.*



## String RS, или semi-Thue systems

Частный случай TRS — SRS (плоские TRS).

- Множество данных — строки (слова) в алфавите  $\mathcal{A}$ .
- Правила переписывания имеют вид  $u \rightarrow v$ , где  $u, v$  — строки из  $\mathcal{A}^*$ .
- Правило  $u \rightarrow v$  применимо к строке  $\Phi$ , если  $\Phi$  содержит хотя бы одну подстроку  $u$ .
- В общем случае применение не детерминированно.



## String RS, или semi-Thue systems

Частный случай TRS — SRS (плоские TRS).

- Множество данных — строки (слова) в алфавите  $\mathcal{A}$ .
- Правила переписывания имеют вид  $u \rightarrow v$ , где  $u, v$  — строки из  $\mathcal{A}^*$ .
- Правило  $u \rightarrow v$  применимо к строке  $\Phi$ , если  $\Phi$  содержит хотя бы одну подстроку  $u$ .
- В общем случае применение не детерминированно.

Каково множество нормализованных строк в алфавите  $\{\mathbf{A}, \mathbf{B}\}$  относительно системы правил  $\mathbf{AB} \rightarrow \varepsilon, \mathbf{AA} \rightarrow \mathbf{A}$ ? относительно только правила  $\mathbf{AB} \rightarrow \varepsilon$ ?



## Выразительная сила SRS

### Теорема


SRS позволяют выразить любую рекурсивную функцию.

Доказательство: алгоритмы Маркова.

### Определение

Нормальный алгоритм (алгоритм) Маркова (НАМ) — это SRS с детерминированным поведением:

- top-down сопоставление (от верхних правил к нижним);
- выбор самой левой подстроки;
- существование терминальных правил.



# Грамматики

## Определение

Грамматика — это четвёрка  $G = \langle N, \Sigma, P, S \rangle$ , где:

- $N$  — алфавит нетерминалов;
- $\Sigma$  — алфавит терминалов;
- $P$  — множество правил переписывания  $\alpha \rightarrow \beta$  типа  $\langle (N \cup \Sigma)^+ \times (N \cup \Sigma)^* \rangle$ ;
- $S \in N$  — начальный символ.

$\alpha \Rightarrow \beta$ , если  $\alpha = \gamma_1 \alpha' \gamma_2$ ,  $\beta = \gamma_1 \beta' \gamma_2$ , и  $\alpha' \rightarrow \beta' \in P$ .

$\Rightarrow^*$  — рефлексивное транзитивное замыкание  $\Rightarrow$ .

## Определение

Язык  $L(G)$ , порождаемый  $G$  — множество  $\{u \mid u \in \Sigma^* \text{ \& } S \Rightarrow^* u\}$ .



## $\alpha$ -преобразование

По-разному воспринимают переименовку:

- Переменные vs конструкторы в TRS;
- Нетерминалы vs терминалы в грамматиках.



## $\alpha$ -преобразование

По-разному воспринимают переименовку:

- Переменные vs конструкторы в TRS;
- Нетерминалы vs терминалы в грамматиках.

Для любой инъективной  $\sigma$  применение  $\sigma$  к правилам грамматики/trs для переменных и нетерминалов также называется  $\alpha$ -преобразованием.

- $\alpha$ -преобразование не меняет терминальный язык;
- обычно термы различаются с точностью до  $\alpha$ -преобразования.



## $\alpha$ -преобразование

По-разному воспринимают переименовку:

- Переменные vs конструкторы в TRS;
- Нетерминалы vs терминалы в грамматиках.

Для любой инъективной  $\sigma$  применение  $\sigma$  к правилам грамматики/trs для переменных и нетерминалов также называется  $\alpha$ -преобразованием.

- $\alpha$ -преобразование не меняет терминальный язык;
- обычно термы различаются с точностью до  $\alpha$ -преобразования.

Неформально: контейнеры определяются не именем, а содержимым (см. экстенциональность в логике).





## Иерархия Хомского без $\varepsilon$ -правил

$A, B \in N$ ,  $a \in \Sigma^*$ ,  $\alpha, \beta \in (N \cup \Sigma)^*$ ,  $\gamma \in (N \cup \Sigma)^+$

### Иерархия грамматик

Тип 0	Рекурсивно-перечислимые	$\forall$
Тип 1	Контекстно-зависимые	$\alpha A \beta \rightarrow \alpha \gamma \beta, \gamma \neq \varepsilon$
Тип 2	Контекстно-свободные	$A \rightarrow \gamma$
Тип 3	Праволинейные (регулярные)	$A \rightarrow a, A \rightarrow aB$



## Иерархия Хомского без $\varepsilon$ -правил

$A, B \in N$ ,  $\alpha \in \Sigma^*$ ,  $\alpha, \beta \in (N \cup \Sigma)^*$ ,  $\gamma \in (N \cup \Sigma)^+$

### Иерархия грамматик

Тип 0	Рекурсивно-перечислимые	$\forall$
Тип 1	Контекстно-зависимые	$\alpha A \beta \rightarrow \alpha \gamma \beta, \gamma \neq \varepsilon$
Тип 2	Контекстно-свободные	$A \rightarrow \gamma$
Тип 3	Праволинейные (регулярные)	$A \rightarrow a, A \rightarrow aB$

### Примеры языков

Тип 0	$\{u \mid L(u) = L(r)\}$ , $r$ — фикс. regex, $u$ — regex;
Тип 1	$\{www \mid w \in \Sigma^+\}$
Тип 2	непустые палиндромы в алфавите $\{a, b\}$
Тип 3	$\{w \mid w = aw_1 \ \& \ (w = a^{2k} \vee w = a^{3k} \vee w \neq a^{5k})\}$



## Иерархия Хомского с $\varepsilon$ -правилами

$A, B \in N$ ,  $a \in \Sigma^*$ ,  $\alpha, \beta \in (N \cup \Sigma)^*$ ,  $\gamma \in (N \cup \Sigma)^+$ .

### Иерархия грамматик

Тип 0	Рекурсивно-перечислимые	$\forall$
Тип 1	Контекстно-зависимые	$\alpha A \beta \rightarrow \alpha \gamma \beta, \gamma \neq \varepsilon$ $\forall S \rightarrow \varepsilon \ \& \ \forall p : \alpha \rightarrow \beta \in P \forall \beta_1, \beta_2 (\beta \neq \beta_1 \beta_2)$
Тип 2	Контекстно-свободные	$A \rightarrow \alpha$
Тип 3	Регулярные	$A \rightarrow a, A \rightarrow aB, A \rightarrow \varepsilon$



## Академические регулярные выражения $\mathcal{RE}$

### Допустимые операции

- $A^*$  — замыкание Клини — ноль или больше итераций  $A$ ;
- $A^+$  — одна или больше итерация  $A$ ;
- $A?$  — 0 или 1 вхождение  $A$ ;
- $A|B$  — альтернатива (вхождение либо  $A$ , либо  $B$ ).



## Академические регулярные выражения $\mathcal{RE}$

### Допустимые операции

- $A^*$  — замыкание Клини — ноль или больше итераций  $A$ ;
- $A^+$  — одна или больше итерация  $A$ ;
- $A?$  — 0 или 1 вхождение  $A$ ;
- $A|B$  — альтернатива (вхождение либо  $A$ , либо  $B$ ).

### Следствия

Если  $r_1, r_2 \in \mathcal{RE}$ , тогда

- $r_1|r_2 \in \mathcal{RE}$ ;
- $r_1r_2 \in \mathcal{RE}$ ;
- $r_1^*, r_2^+ \in \mathcal{RE}$ .



## Операции в регулярных грамматиках

### Объединение

Дано:  $G_1$  и  $G_2$  — праволинейные. Построить  $G : L(G) = L(G_1) \cup L(G_2)$ .

- 1 Переименовать нетерминалы из  $N_1$  и  $N_2$ , чтобы стало  $N_1 \cap N_2 = \emptyset$  (сделать  $\alpha$ -преобразование). Применить переименовку к правилам  $G_1$  и  $G_2$ .
- 2 Объявить стартовым символом свежий нетерминал  $S$  и для всех правил  $G_1$  вида  $S_1 \rightarrow \alpha$  и правил  $G_2$  вида  $S_2 \rightarrow \beta$ , добавить правила  $S \rightarrow \alpha$ ,  $S \rightarrow \beta$  в правила  $G$ .
- 3 Добавить в правила  $G$  остальные правила из  $G_1$  и  $G_2$ .



## Операции в регулярных грамматиках

### Конкатенация

Дано:  $G_1$  и  $G_2$  — праволинейные. Построить  $G : L(G) = L(G_1)L(G_2)$ .

- 1 Переименовать нетерминалы из  $N_1$  и  $N_2$ , чтобы стало  $N_1 \cap N_2 = \emptyset$  (сделать  $\alpha$ -преобразование).
- 2 Построить из  $G_1$  её вариант без  $\varepsilon$ -правил (см. ниже).
- 3 По всякому правилу из  $G_1$  вида  $A \rightarrow a$  строим правило  $G$  вида  $A \rightarrow aS_2$ , где  $S_2$  — стартовый нетерминал  $G_2$ .
- 4 Добавить в правила  $G$  остальные правила из  $G_1$  и  $G_2$ . Объявить  $S_1$  стартовым.
- 5 Если  $\varepsilon \in L(G_1)$  (до шага 2), то по всем  $S_2 \rightarrow \beta$  добавить правило  $S_1 \rightarrow \beta$ .



## Операции в регулярных грамматиках

### Положительная итерация Клини

Дано:  $G_1$  — праволинейная. Построить  $G : L(G) = L(G_1)^+$ .

- 1 Построить из  $G_1$  её вариант без  $\varepsilon$ -правил.
- 2 По всякому правилу из  $G_1$  вида  $A \rightarrow a$  строим правило  $G$  вида  $A \rightarrow aS_1$ , где  $S_1$  — стартовый нетерминал  $G_1$ .
- 3 Добавить в правила  $G$  все (включая вида  $A \rightarrow a$ ) правила из  $G_1$ . Объявить  $S_1$  стартовым.
- 4 Если  $\varepsilon \in L(G_1)$  (до шага 2), добавить правило  $S_1 \rightarrow \varepsilon$  и вывести  $S_1$  из рекурсии.






## Построение грамматики без $\varepsilon$ -правил

Дано:  $G$  — праволинейная. Построить  $G'$  без правил вида  $A \rightarrow \varepsilon$  такую, что  $L(G') = L(G)$  или  $L(G') \cup \{\varepsilon\} = L(G)$ .

- 1 Перенести в  $G'$  все правила  $G$ , не имеющие вид  $A \rightarrow \varepsilon$ .
- 2 Если существует правило  $A \rightarrow \varepsilon$ , то по всем правилам вида  $B \rightarrow \alpha A$  дополнительно строим правила  $B \rightarrow \alpha$ .



## Пересечение регулярных грамматик

Дано:  $G_1, G_2$  — праволинейные. Построить  $G'$  такую, что

$$L(G') = L(G_1) \cap L(G_2).$$

- ❶ Построить стартовый символ  $G'$  — пару  $\langle S_1, S_2 \rangle$ , где  $S_i$  — стартовый символ грамматики  $G_i$ .
- ❷ Поместить  $\langle S_1, S_2 \rangle$  в множество  $U$  неразобранных нетерминалов. Множество  $T$  разобранных нетерминалов объявить пустым.
- ❸ Для каждого очередного нетерминала  $\langle A_1, A_2 \rangle \in U$ :
  - ❶ если  $A_1 \rightarrow a \in G_1, A_2 \rightarrow a \in G_2$ , тогда добавить в  $G'$  правило  $\langle A_1, A_2 \rangle \rightarrow a$ ;
  - ❷ если  $A_1 \rightarrow aA_3 \in G_1, A_2 \rightarrow aA_4 \in G_2$ , тогда добавить в  $G'$  правило  $\langle A_1, A_2 \rangle \rightarrow a\langle A_3, A_4 \rangle$ , а в  $U$  — нетерминал  $\langle A_3, A_4 \rangle$ , если его ещё нет в множестве  $T$ ;
  - ❸ если все пары правил, указанные выше, были обработаны, тогда переместить  $\langle A_1, A_2 \rangle$  из  $U$  в  $T$ .
- ❹ Повторять шаг 3, пока множество  $U$  не пусто.
- ❺ Если  $\varepsilon \in L(G_1) \ \& \ \varepsilon \in L(G_2)$ , тогда добавить в  $G'$  правило  $\langle S_1, S_2 \rangle \rightarrow \varepsilon$ .



## От $\mathcal{RE}$ к грамматике

### Теорема

Если  $E \in \mathcal{RE}$ , то существует праволинейная регулярная грамматика  $G$  такая, что  $L(G) = L(E)$



## От $\mathcal{RE}$ к грамматике

### Теорема

Если  $E \in \mathcal{RE}$ , то существует праволинейная регулярная грамматика  $G$  такая, что  $L(G) = L(E)$

Для каждой константы  $a_i$  в  $E$  построим правило  $S_i \rightarrow a_i$ .  
Объявим грамматику с одним этим правилом  $G_i$ .  
Последовательно соберём из таких грамматик грамматику для  $E$ , используя вышеописанные операции итерации, конкатенации, объединения.

Построим регулярную грамматику для  $(a|(ab))^*b^+$ .

- Объявим исходные правила:  $S_1 \rightarrow a$ ,  $S_2 \rightarrow ab$ ,  $S_3 \rightarrow b$  (для краткости сразу для  $ab$ ).
- Создадим грамматику  $G_4$  для  $G_1 \cup G_2$ :  
 $S_4 \rightarrow a$     $S_4 \rightarrow ab$
- По  $G_4$  построим  $G_5 = (G_4)^*$ :  
 $S_5 \rightarrow aT$     $S_5 \rightarrow abT$     $S_5 \rightarrow \varepsilon$   
 $S_5 \rightarrow a$     $S_5 \rightarrow ab$     $T \rightarrow a$   
 $T \rightarrow aT$     $T \rightarrow abT$     $T \rightarrow ab$
- По  $G_3$  построим  $G_6 = (G_3)^+$ :  $S_6 \rightarrow bS_6$ ,  $S_6 \rightarrow b$ .
- Осталось построить  $G_7 = G_5G_6$ . Удаляем  $\varepsilon$ -правило:

$$\begin{array}{llll} S_5 \rightarrow aT & S_5 \rightarrow abT & S_5 \rightarrow a & S_5 \rightarrow ab \\ T \rightarrow a & T \rightarrow aT & T \rightarrow abT & T \rightarrow ab \end{array}$$

Проводим конкатенацию и возвращаем  $\varepsilon$ -правило:

$$\begin{array}{llll} S_5 \rightarrow aT & S_5 \rightarrow abT & S_5 \rightarrow aS_6 & S_5 \rightarrow abS_6 \\ T \rightarrow aS_6 & T \rightarrow aT & T \rightarrow abT & T \rightarrow abS_6 \\ S_5 \rightarrow b & S_5 \rightarrow bS_6 & S_6 \rightarrow bS_6 & S_6 \rightarrow b \end{array}$$



## Неподвижная точка $\mathcal{RE}$

### Лемма Ардена

Пусть  $X = (AX) \mid B$ , где  $X$  — неизвестное  $\mathcal{RE}$ , а  $A, B$  — известные, причём  $\varepsilon \notin L(A)$ . Тогда  $X = (A)^*B$ .

Рассмотрим систему уравнений:

$$X_1 = (A_{11}X_1) \mid (A_{12}X_2) \mid \dots \mid B_1$$

$$X_2 = (A_{21}X_1) \mid (A_{22}X_2) \mid \dots \mid B_2$$

...

$$X_n = (A_{n1}X_1) \mid (A_{n2}X_2) \mid \dots \mid B_n$$

Положим  $\varepsilon \notin A_{ij}$ . Будем последовательно выражать  $X_1$  через  $X_2, \dots, X_n$ ,  $X_2$  через  $X_3 \dots X_n$  и т.д. Получим регулярное выражение для  $X_n$ .



## От грамматики к $\mathcal{RE}$

- Объявляем каждый нетерминал переменной и строим для него уравнение:
  - По правилу  $A \rightarrow aB$  добавляем альтернативу  $aB$ ;
  - По правилу  $A \rightarrow b$  добавляем альтернативу без переменных.
  - Правило  $S \rightarrow \varepsilon$  обрабатываем отдельно, не внося в уравнение: добавляем в язык альтернативу  $(\mathcal{RE} \mid \varepsilon)$ .
- Решаем систему относительно  $S$ .



## От грамматики к $\mathcal{RE}$

### Пример

Построим  $\mathcal{RE}$  по грамматике:

$$S \rightarrow aT \quad S \rightarrow abS$$

$$T \rightarrow aT \quad T \rightarrow bT \quad T \rightarrow b$$

Строим по правилам грамматики систему:

$$S = (abS) | (aT)$$

$$T = ((a|b)T) | b$$

Решаем второе уравнение:

$$T = (a|b)^*b$$

Подставляем в первое:

$$S = (abS) | (a(a|b)^*b)$$

Получаем ответ:

$$S = (ab)^*a(a|b)^*b$$