#### Восходящий разбор

Теория формальных языков *2021 г*.



# Детерминированные КС-языки

Язык L обладает префикс-свойством (prefix-free), если  $\forall w(w \in L \Rightarrow \forall v(v \neq \varepsilon \Rightarrow wv \notin L)).$ 



# Детерминированные КС-языки

Язык L обладает префикс-свойством (prefix-free), если  $\forall w(w \in L \Rightarrow \forall v(v \neq \varepsilon \Rightarrow wv \notin L)).$ 

Детерминированные языки с префикс-свойством — языки, распознаваемые DPDA с допуском по пустому стеку.

Рассмотрим язык  $\alpha^+$ . Предположим, он распознаётся DPDA с допуском по пустому стеку. Тогда на элементе  $\alpha$  стек уже обязательно пуст. А значит, работа DPDA не может быть продолжена, и элемент  $\alpha\alpha$  не может быть им распознан.



### Детерминированные КС-языки

Язык L обладает префикс-свойством (prefix-free), если  $\forall w(w \in L \Rightarrow \forall v(v \neq \varepsilon \Rightarrow wv \notin L)).$ 

Детерминированные языки с префикс-свойством — языки, распознаваемые DPDA с допуском по пустому стеку.

Рассмотрим язык L,  $w_1, w_1w_2 \in L$ ,  $w_2 \neq \varepsilon$ . Предположим, он распознаётся DPDA с допуском по пустому стеку. Тогда на элементе  $w_1$  стек уже обязательно пуст. А значит, работа DPDA не может быть продолжена, и элемент  $w_1w_2$  не может быть им распознан.



# Эндмаркеры

Рассмотрим язык  $\alpha^+$ \$ (алфавит терминалов  $\Sigma = \{\alpha, \$\}$ ). В этом языке ни одно слово не является префиксом другого.



#### Эндмаркеры

Рассмотрим язык  $\{w\$\,|\,w\in L\}$  (алфавит терминалов  $\Sigma=\Sigma_L\cup\{\$\}$ ,  $\$\not\in\Sigma_L$ ). Независимо от L, в этом языке ни одно слово не является префиксом другого.

 Хорошие новости: любой детерминированный КС-язык легко преобразовать в язык, распознаваемый DPDA с допуском по пустому стеку.



#### Эндмаркеры

Рассмотрим язык (алфавит терминалов). этом языке ни одно слово не является префиксом другого.

- Хорошие новости: любой детерминированный КС-язык легко преобразовать в язык, распознаваемый DPDA с допуском по пустому стеку.
- Плохие новости: существенно неоднозначные контекстно-свободные языки с префикс-свойством. Стандартный пример:  $\{a^nb^nc^md\} \cup \{a^mb^nc^nd\}$ .



## Языки нередуцируемых префиксов

Определим понятие свёртки — перехода справа налево в правиле переписывания  $A \to \alpha$ . Что можно сказать о всех возможных префиксах сентенциальных форм, порождаемых грамматикой G, к которым нельзя применить ни одну свёртку?



### Языки нередуцируемых префиксов

Определим понятие свёртки — перехода справа налево в правиле переписывания  $A \to \alpha$ . Что можно сказать о всех возможных префиксах сентенциальных форм, порождаемых грамматикой G, к которым нельзя применить ни одну свёртку?

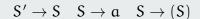
Такие с.ф. образуют регулярный язык. Идея обоснования: в распознающем их PDA из стека ничего не читается, т.е. PDA учитывает только символы сент. формы и свои состояния.

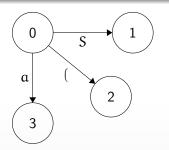


#### Описание конструкции

- Отмеченная позиция в правиле: •. В правиле с правой частью  $\xi_1 \dots \xi_n$  есть n+1 таких позиций.
- Правило  $A \to \alpha \bullet B\beta$  и правило  $B \to \bullet \gamma$  одно и то же множество переходов по символу, не приводящих к редукции  $\Rightarrow$  в одном состоянии.
- При чтении элемента правой части сдвигаем вправо на позицию.



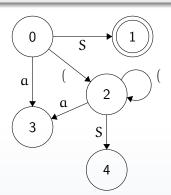




0	$S' \to \bullet S$ $S \to \bullet (S)$
	$S \rightarrow \bullet a$
1	S'  o S ullet
2	$S \to (\bullet S)$
3	$S \rightarrow a \bullet$



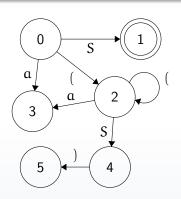
$$S' \to S \quad S \to \alpha \quad S \to (S)$$



0	$S' \rightarrow \bullet S$
	$S \to \bullet(S)$
	$S \to ullet a$
1	S'  o S ullet
2	$S \to (\bullet S)$
	$S \to \bullet(S)$
	$S \to ullet a$
3	S  o a ullet
4	$S \to (S ullet)$



$$S' \rightarrow S \quad S \rightarrow \alpha \quad S \rightarrow (S)$$



0	$S' \rightarrow \bullet S$
	$S \to \bullet(S)$
	$S \to ullet a$
1	S'  o S ullet
2	$S \to (\bullet S)$
	$S \to \bullet(S)$
	$S \to ullet a$
3	S  o a ullet
4	$S \to (S ullet)$
5	$S \to (S) \bullet$



- $\bullet$  Финальное (свёртка в S').
- Не финальное, но свёртка.
- 3 Сдвиг по символу сентенциальной формы.

Что хранить в стеке PDA, построенного по такому автомату?



- $\bullet$  Финальное (свёртка в S').
- Не финальное, но свёртка.
- 3 Сдвиг по символу сентенциальной формы.

Что хранить в стеке PDA, построенного по такому автомату?

 Хранить сами сентенциальные формы плохо проблема с извлечением нескольких подряд символов.



- $\bullet$  Финальное (свёртка в S').
- Не финальное, но свёртка.
- 3 Сдвиг по символу сентенциальной формы.

Что хранить в стеке PDA, построенного по такому автомату?

- Хранить сами сентенциальные формы плохо проблема с извлечением нескольких подряд символов.
- Логично хранить последовательности последних символов с.ф., которые могут привести к разным свёрткам, закодированными одним символом стека.



- $\bullet$  Финальное (свёртка в S').
- Не финальное, но свёртка.
- 3 Сдвиг по символу сентенциальной формы.

Что хранить в стеке PDA, построенного по такому автомату?

- Хранить сами сентенциальные формы плохо проблема с извлечением нескольких подряд символов.
- Логично хранить последовательности последних символов с.ф., которые могут привести к разным свёрткам, закодированными одним символом стека.
- А это в точности состояния автомата.



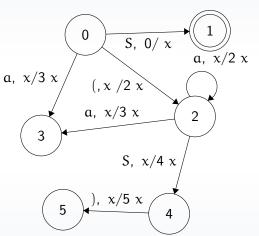
# PDA по LR(0)-автомату

#### Общая конструкция

- При каждом сдвиге кладём в стек номер состояния, в которое приходим в конечном автомате.
- При каждой свёртке извлекаем из стека n символов, где n длина правой части  $\beta$  правила  $A \to \beta$ , после чего переходим в состояние с номером n+1-ого символа в стеке по символу A.



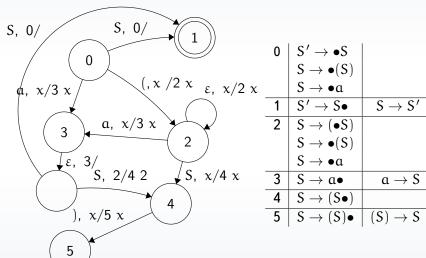
#### Пример построения PDA



0	S'  o ullet S	
	$S \to \bullet(S)$	
	$S\to \bullet \mathfrak{a}$	
1	$S' \to S ullet$	$S \rightarrow S'$
2	$S \to (\bullet S)$	
	$S \to \bullet(S)$	
	$S \to \bullet \mathfrak{a}$	
3	S  o a ullet	$a \rightarrow S$
4	$S \to (S ullet)$	
5	$S \to (S) \bullet$	$(S) \rightarrow S$

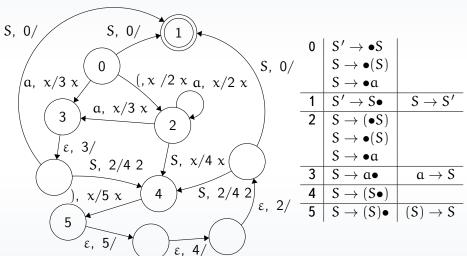


#### Пример построения PDA





#### Пример построения PDA





# PDA или DPDA?

- Если есть  $\varepsilon$ -переходы, то нет никаких других.
- ullet Если есть arepsilon-переход, то он единственный из данного состояния.



# PDA или DPDA?

- Если есть  $\varepsilon$ -переходы, то нет никаких других. Если делается свёртка, то нельзя сделать сдвиг.
- Если есть ε-переход, то он единственный из данного состояния. Если делается свёртка одного типа, то нельзя сделать свёртку другого типа.
- Допуск по пустому стеку  $\Rightarrow$  DPDA для языков с префикс-свойством.
- DPDA с допуском по пустому стеку распознают те же языки, что и LR(0)-разбор.
- В конструкции LR(0)-автомата часто навязывается эндмаркер ⇒ изначальная грамматика может описывать не LR(0)-язык!



# Отказ от эндмаркера и SLR

- Используем ту же конструкцию автомата.
- Разрешим при возможности сделать свёртку вида  $\beta \to A$  заглянуть в множество FOLLOW(A), чтобы понять, какую свёртку делать (и делать ли).



### Отказ от эндмаркера и SLR

- Используем ту же конструкцию автомата.
- Разрешим при возможности сделать свёртку вида  $\beta \to A$  заглянуть в множество FOLLOW(A), чтобы понять, какую свёртку делать (и делать ли).

Здесь есть конфликт свёрток для S' (по  $V \to id \bullet$  и  $T \to id \bullet$ ), но  $FOLLOW_1(V) \cap FOLLOW_1(T) = \emptyset \Rightarrow$  эта грамматика — SLR(1).

10 / 18



# Коллапс линейных парсеров

#### Теорема

Для всякого языка из класса DCFL существует распознающая его SLR(1)-грамматика.



# *Теоретический* парсеров

коллапс линейных

#### Теорема

Для всякого языка из класса DCFL существует распознающая его SLR(1)-грамматика.

Следует из теоремы:

Для всякого языка из класса DCFL существует распознающая его LR(k)-грамматика.



#### LR(k)-распознаватели

Грамматика G = LR(k), тогда и только тогда, когда для всех пар сентенциальных форм xy, xy', порождаемых правосторонним разбором, где  $y,y'\in \Sigma^+$ , таких что xy допускает правую свёртку в префиксе y по правилу  $\xi_1$ , а xy' — свёртку где угодно по правилу  $\xi_2$ , и первые k символов y и y' совпадают,  $\xi_1 = \xi_2$ .



# 

Грамматика G - LR(k), тогда и только тогда, когда для всех пар сентенциальных форм xy, xy', порождаемых правосторонним разбором, где  $y, y' \in \Sigma^+$ , таких что xyдопускает правую свёртку в префиксе y по правилу  $\xi_1$ , а xy' — свёртку где угодно по правилу  $\xi_2$ , и первые kсимволов y и y' совпадают,  $\xi_1 = \xi_2$ .

$$\begin{array}{lll} S' \rightarrow S & S \rightarrow L = R; & S \rightarrow R; \\ L \rightarrow id & L \rightarrow *R & R \rightarrow L \end{array}$$

Поскольку  $= \in FOLLOW_1(R)$ , возникает конфликт вида сдвиг-свёртка при попытке анализа с.ф. L. Ho lookahead у L, порождённой посредством  $S \to L = R$ , и посредством  $S \to R$ ;  $\to L$ ;, будет разный.



# LR(k)-распознаватели

Грамматика G - LR(k), тогда и только тогда, когда для всех пар сентенциальных форм xy, xy', порождаемых правосторонним разбором, где  $y,y' \in \Sigma^+$ , таких что xyдопускает правую свёртку в префиксе y по правилу  $\xi_1$ , а xy' — свёртку где угодно по правилу  $\xi_2$ , и первые kсимволов y и y' совпадают,  $\xi_1 = \xi_2$ .

Любая LR(k)-грамматика по определению гарантирует однозначный разбор при определённой длине lookahead-строки, поэтому ни одна грамматика с неоднозначным разбором не является LR(k) ни для какого значения k.



# 

$$\begin{array}{cccc} S' \rightarrow S & S \rightarrow Abb & S \rightarrow Bbc \\ A \rightarrow \alpha A & A \rightarrow \alpha & B \rightarrow \alpha B \\ & B \rightarrow \alpha & \end{array}$$

He LR(1), из-за свёрток  $A \to a$ ,  $B \to a$ . Используем трансформацию присоединения правого контекста:

$$\begin{array}{lll} S' \to S & S \to [Ab]b & S \to [Bb]c \\ [Ab] \to \alpha [Ab] & [Ab] \to \alpha b & [Bb] \to \alpha [Bb] \\ & [Bb] \to \alpha b & \end{array}$$



# $LR(k) \rightarrow LR(1)$ , Mickunas-Lancaster-Shneider

$$S' \rightarrow S$$
  $S \rightarrow bSS$   $S \rightarrow a$   
 $S \rightarrow aac$ 

Не LR(1), конфликт свёртки на префиксе ba с контекстом a. Используем трансформацию уточнения правого контекста:

#### Теперь присоединим правые контексты:

/ 1



Исследовать на детерминированность язык  $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$ 

Видно, что если язык L распознаётся DPDA (т.е. является LR(1)-языком), то он также является LR(0)-языком, поскольку удовлетворяет префикс-свойству. Действительно, любое слово этого языка содержит единственную букву c, причём она расположена точно в середине слова.

Построим пробную КС-грамматику для языка L:

$$S \rightarrow aSb|aCa|bCb|c$$

$$C \rightarrow aCa|bCb|c$$

Проверим, является ли она LR(0)-грамматикой. Для этого построим LR(0)-автомат и проанализируем его на конфликты.



# Исследовать на детерминированность язык $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$

Пробная грамматика для L: 
$$\begin{array}{ccc} S & \to & aSb \, | \, aCa \, | \, bCb \, | \, c \\ C & \to & aCa \, | \, bCb \, | \, c \end{array}$$

Начинаем строить LR(0)-автомат. Для этого вводим новое стартовое состояние S' (состояние окончательной свёртки) и начинаем разбор правила  $S' \to \bullet S$ . Поскольку отмеченная позиция в правиле находится перед нетерминалом S, добавляем в состояние все ситуации вида  $S \to \bullet \alpha$ . Переходы по нетерминалу S и терминалу C ведут к бесконфликтным свёрткам, поэтому малоинтересны. Разберёмся C переходом по C.

$$S' \rightarrow \bullet S$$

$$S \rightarrow \bullet aSb$$

$$S \rightarrow \bullet aCa$$

$$S \rightarrow \bullet bCb$$

$$S \rightarrow \bullet c$$



# Исследовать на детерминированность язык $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$

Пробная грамматика для L: 
$$\begin{array}{ccc} S & \to & aSb \, | \, aCa \, | \, bCb \, | \, c \\ C & \to & aCa \, | \, bCb \, | \, c \end{array}$$

Переходы по нетерминалу S и терминалу c ведут к бесконфликтным свёрткам, поэтому малоинтересны. Разберёмся с переходом по a.

$$\begin{pmatrix} S' \rightarrow \bullet S \\ S \rightarrow \bullet aSb \\ S \rightarrow \bullet aCa \\ S \rightarrow \bullet bCb \\ S \rightarrow \bullet c \end{pmatrix} \xrightarrow{\alpha} \begin{pmatrix} S \rightarrow \alpha \bullet Sb \\ S \rightarrow \alpha \bullet Ca \\ S \rightarrow \bullet aSb \\ S \rightarrow \bullet aCa \\ S \rightarrow \bullet bCb \\ S \rightarrow \bullet c \\ C \rightarrow \bullet aCa \\ C \rightarrow \bullet bCb \\ C \rightarrow \bullet c \end{pmatrix}$$

Похоже, что есть потенциальный конфликт (даже два) по свёрткам в S и C. Построим конфликтное состояние явно.



# Исследовать на детерминированность язык $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$

Пробная грамматика для L: 
$$egin{array}{ccc} S & \to & aSb \,|\, aCa \,|\, bCb \,|\, c \\ C & \to & aCa \,|\, bCb \,|\, c \end{array}$$

Похоже, что есть потенциальный конфликт (даже два) по свёрткам в S и C. Построим конфликтное состояние явно.

Присоединим к конфликтующим S и C-нетерминалам их правые контексты.



Исследовать на детерминированность язык  $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$ 

```
Пробная грамматика для L: \begin{array}{ccc} S & \to & aSb \,|\, aCa \,|\, bCb \,|\, c \\ C & \to & aCa \,|\, bCb \,|\, c \end{array}
```

Грамматика для L после присоединения правых контекстов к нетерминалам S и C методом MLS (новые нетерминалы выделены красным):

Можно построить LR(0)-автомат для этой грамматики и убедиться, что он не содержит конфликтов. Значит язык L — детерминированный (более того, LR(0)).



# Другой подход к анализу КС-языков

# Исследовать на детерминированность язык $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$

Можно сразу попробовать построить DPDA для L. Заметим, что до прочтения буквы c стек обязательно заполняется (иначе потеряется информация либо о структуре палиндрома, либо о количестве букв  $\alpha$  в начале слова), причём, поскольку неизвестно, когда именно префикс  $\alpha^{\rm n}$  переходит в палиндром, придётся запоминать, какие конкретные буквы были прочитаны: считаем, что символ стека A соответствует  $\alpha$ , символ B — терминалу b.

b, 
$$\forall /B \forall a$$
,  $\forall /A \forall$ 

Для экономии места символ  $\forall$  использован в роли параметра, пробегающего значения A, B и  $Z_0$ : на детерминированность это не влияет, поскольку переходы с его участием делаются по разным терминалам.

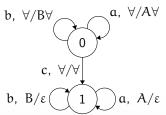
15 / 18



# Другой подход к анализу КС-языков

# Исследовать на детерминированность язык $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$

После прочтения буквы c стек только опустошается: структура оставшейся части слова определяется уже прочитанной его частью.



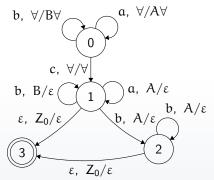
Единственная тонкость — это переход от чтения  $w^R$  к чтению  $b^n$ . Он происходит, если на вершине стека лежит A, а читается буква b, и это не приводит к неопределённости, поскольку при чтении буквы b из палиндромной части мы обязаны всегда иметь на вершине стека символ B.



### Другой подход к анализу КС-языков

# Исследовать на детерминированность язык $L = \{a^n w c w^R b^n | w \in \{a, b\}^*\}.$

Добавляем состояние чтения суффикса  $b^n$  (в нём на вершине стека должны быть всегда лишь символы A) и финальное состояние. Легко убедиться, что итоговый стековый автомат — DPDA.





#### Лемма о накачке для DCFL

#### Теорема (S. Yu)

Пусть L — DCFL. Тогда существует такая длина накачки p, что для всех пар слов w,  $w' \in L$ , таких что  $w=xy \ \& \ w'=xz$ , |x|>p и первые буквы y, z совпадают, выполнено одно из двух:

- lacktriangle существует накачка только префикса x (в привычном смысле);
- 2 существует разбиение  $x=x_1x_2x_3$ ,  $y=y_1y_2y_3$ ,  $z=z_1z_2z_3$  такое, что  $|x_2x_3|\leqslant p$ ,  $|x_2|>0$ , и  $\forall i(x_1x_2^ix_3y_1y_2^iy_3\in L\ \&\ x_1x_2^ix_3z_1z_2^iz_3\in L).$



#### Лемма о накачке для DCFL

#### Теорема (S. Yu)

Пусть L — DCFL. Тогда существует такая длина накачки p, что для всех пар слов w,  $w' \in L$ , таких что  $w=xy \ \& \ w'=xz$ , |x|>p и первые буквы y, z совпадают, выполнено одно из двух:

- lacktriangle существует накачка только префикса x (в привычном смысле);
- $oldsymbol{2}$  существует разбиение  $x=x_1x_2x_3$ ,  $y=y_1y_2y_3$ ,  $z=z_1z_2z_3$  такое, что  $|x_2x_3|\leqslant \mathfrak{p},\,|x_2|>0$ , и  $orall i(x_1x_2^ix_3y_1y_2^iy_3\in L\ \&\ x_1x_2^ix_3z_1z_2^iz_3\in L).$

Рассмотрим язык  $\{a^nb^n\}\cup\{a^nb^{2n}\}$ , положим  $x=a^nb^{n-1}$ ,  $y=b,\,z=b^{2n-1}$ , где n-1>p. Тогда в случае 2 придётся накачивать в x только b, а в случае 1 нет подходящей накачки.



# Замыкания DCFL

- Замкнуты относительно дополнения (смена конечных состояний в DPDA).
- Замкнуты относительно пересечения с регулярным языком.
- Не замкнуты относительно объединения (см.  $\{a^nb^n\}\cup\{a^nb^{2n}\}$ ).
- Не замкнуты относительно пересечения.



# Замыкания DCFL

- Замкнуты относительно дополнения (смена конечных состояний в DPDA).
- Замкнуты относительно пересечения с регулярным языком.
- Не замкнуты относительно объединения (см.  $\{a^nb^n\}\cup\{a^nb^{2n}\}$ ).
- Не замкнуты относительно пересечения.
- Не замкнуты относительно гомоморфизмов. См.  $\{ca^nb^n\} \cup \{a^nb^{2n}\}.$
- Не замкнуты относительно конкатенации. См.  $L_1 = \{c \, a^n b^n\} \cup \{a^n b^{2n}\}, \ L_2 = c^*.$



### Иерархия Хомского revisited

Утверждения ниже касаются только языков (не грамматик)!

- RegL ⊂ CFL;
- RegL ⊂ DCFL;
- DCFL ⊂ CFL;
- RegL ⊂ LL(1);
- LR(0) не сравним с RegL;
- $\bullet$  LR(0) не сравним с LL(k);
- $LL(k) \subset LL(k+1)$ ;
- LL(k) ⊂ LR(1);
- LR(k) = SLR(1) = DCFL.



